3

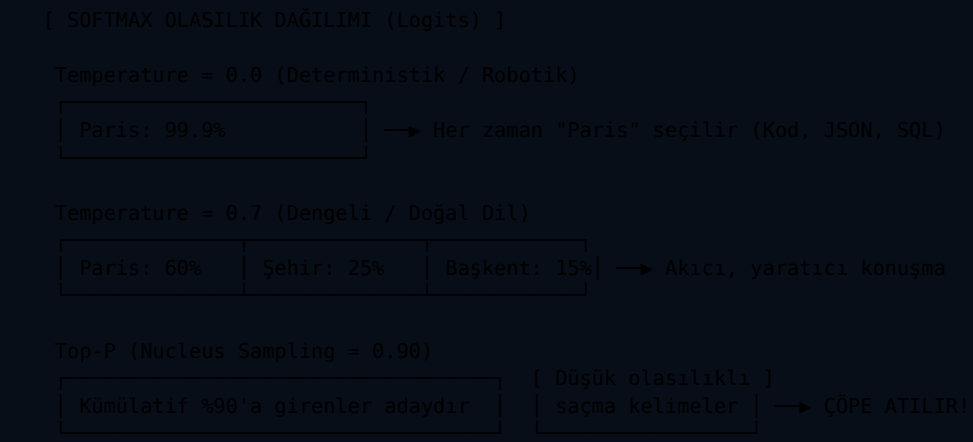
BÖLÜM: AI ENGINEER ROLÜ, LLM ANATOMISI & MAANG MÜLAKAT ÇERÇEVESI | MODULE: THE AI ENGINEER ROLE, LLM ANATOMY & THE MAANG INTERVIEW FRAMEWORK

Model Parametrelerinin Sırları: Temperature, Top-P, Top-K & Penalty Ayarları

Hyperparameter Secrets: Temperature, Top-P, Top-K & Frequency/Presence Penalties

🤖 AI Mimarisi & Veri Akış Şeması

🤖 AI Architecture & Flow



💡 Aptala Anlatım (ELI5 Metaforu)

💡 ELI5 Metaphor

🇹🇷 TÜRKÇE (ELI5)

Bir restoranda garsona 'Bana bir yemek öner' dediğinizde iki seçeneğiniz vardır: Garsonun her defasında menünün en çok satan standart yemeğini getirmesini mi istersiniz (Temperature = 0, tam deterministik); yoksa arada sırada şefin özel spesiyallerini denemesini mi (Temperature = 0.8, yaratıcı)? Eğer SQL sorgusu veya JSON kod üretiyorsanız garsonun fantezi yapmasını istemezsiniz (T=0)! Ama bir pazarlama metni veya hikaye yazdırıyorsanız biraz yaratıcılık gerekir.

🇬🇧 ENGLISH (ELI5)

Imagine dining at a restaurant and asking the chef for a dish. Temperature = 0 means the chef strictly prepares the mathematically 1 top-selling item every single time (deterministic, ideal for code and JSON). Temperature = 0.8 allows the chef to explore delicious variations across top ingredients. If you are generating financial reports, SQL, or JSON APIs, any Temperature > 0 risks syntactic corruption!

🔍 MAANG Seviyesi Teknik Derinlik

🇹🇷 MAANG DERİNLEMESİNE ANALİZ

Parametrelerin matematiksel anatomisi: 1) Temperature: Logit değerlerini (z_i / T) şeklinde böler. T -> 0 iken dağılım argmax'a dönüşür (tam deterministik). T > 1 iken tüm kelimelerin olasılığı birbirine yaklaşır, halüsinasyon riski fırlar. 2) Top-P (Nucleus Sampling): Olasılıkları azalan sırada sıralar ve toplam kümülatif olasılık P eşiğine (ör. 0.90) ulaşana kadar olan en iyi kelime kümesini alır; kuyruktaki saçma token'ları budar. 3) Frequency & Presence Penalty: Frequency penalty tekrar eden token'ların olasılığını oransal cezalandırır; Presence penalty ise bir kelimenin metinde sadece bir kez geçmiş olmasına ceza keserek modelin yeni konulara geçmesini sağlar.

🔍 MAANG-Level Technical Deep-Dive

🇬🇧 MAANG TECHNICAL DEEP-DIVE

Mathematical dynamics of sampling hyperparameters: 1) Temperature (T): Scales the raw logits before Softmax ($p_i = \exp(z_i / T) / \Sigma \exp(z_j / T)$). As T -> 0, entropy drops to zero, yielding deterministic greedy decoding. 2) Top-P (Nucleus Sampling): Dynamically truncates the probability mass to the smallest subset of tokens whose cumulative sum exceeds P (e.g. 0.9). 3) Frequency vs Presence Penalty: Frequency penalizes repeated token occurrences proportionally; Presence penalizes any token having appeared at least once, encouraging broader topical exploration.

⚡ Java 25, Spring AI & LangChain4j Kodu

⚡ Java 25 & OpenAI Implementation

```java
// Java 25 & LangChain4j: Deterministik JSON Üretimi için Model Ayarları
import dev.langchain4j.model.openai.OpenAiChatModel;

public class ModelParameterFactory {
    // Kurumsal API ve JSON çıktıları için sıfır halüsinasyon modeli
    public static OpenAiChatModel createStrictJsonModel(String apiKey) {
        return OpenAiChatModel.builder()
            .apiKey(apiKey)
            .modelName("gpt-4o-mini")
            .temperature(0.0)      // Kesinlikle deterministik
            .topP(1.0)
            .presencePenalty(0.0)
            .frequencyPenalty(0.0)
            .maxRetries(3)
            .build();
    }

    // Yaratıcı Pazarlama ve Metin Yazarlığı Modeli
    public static OpenAiChatModel createCreativeModel(String apiKey) {
        return OpenAiChatModel.builder()
            .apiKey(apiKey)
            .modelName("gpt-4o")
            .temperature(0.75)     // Zengin ve doğal dil
            .topP(0.90)            // Düşük ihtimalli saçmalıkları buda
            .build();
    }
}
```

⚠️ Halüsinasyon, Güvenlik & Mülakat Tuzağı

⚠️ Hallucination & Interview Trap

🇹🇷 MÜLAKAT TUZAĞI VE HALÜSİNASYON

Kritik Mülakat Kuralı: Aynı anda hem yüksek Temperature (ör. 0.9) hem de düşük Top-P (ör. 0.2) kullanmayın! Bu iki hiperparametre birbiriyle yarışır. OpenAI resmi rehberi: Ya Temperature'ı ya da Top-P'yi değiştirin, ikisini aynı anda kurcalamayın.

🇬🇧 INTERVIEW TRAP & HALLUCINATION RISK

Production guideline: Never tune Temperature and Top-P concurrently. OpenAI officially recommends altering either Temperature OR Top-P, never both simultaneously, to avoid conflicting probability distributions.

🎯 Mülakatta Hatırlanacak Altın Çıkarımlar

• JSON, kod ve SQL üretiminde Temperature daima 0.0 olmalıdır.

• Top-P (Nucleus Sampling), modelin saçma ve alakasız kelimeleri seçmesini önler.

• Production sistemlerde hiperparametreler harici konfigürasyondan dinamik yönetilmelidir.

🎯 Key Takeaways for the Interview

• For JSON, code generation, and SQL querying, Temperature must strictly be 0.0.

• Top-P truncates the long tail of low-probability hallucinated tokens.

• In production systems, hyperparameters should be dynamically configured per use-case.