11

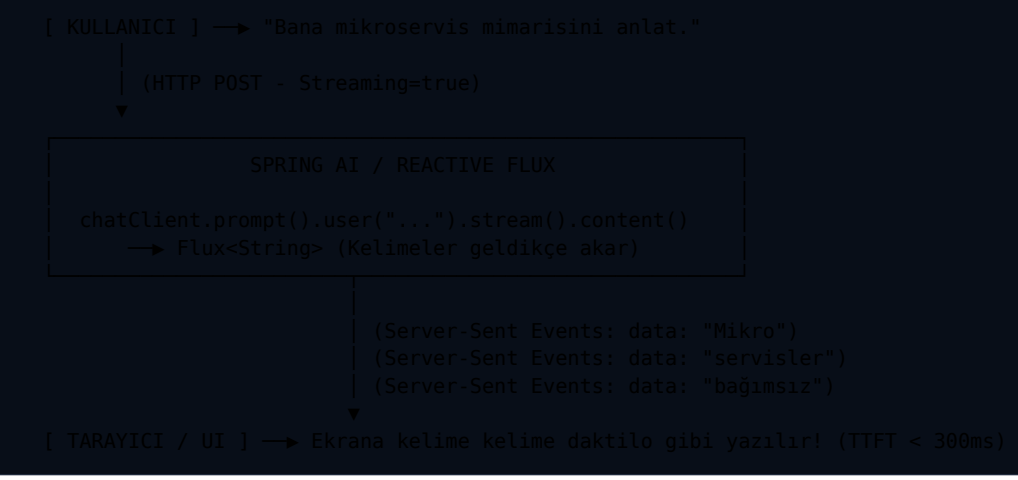
BÖLÜM: SPRING AI & LANGCHAIN4J TEMEL YAPI TAŞLARI VE CHAT MODELLERI | MODULE: CORE FOUNDATIONS: SPRING AI, LANGCHAIN4J & MODERN CHAT MODELS

Gerçek Zamanlı Streaming (SSE, Flux, Reactor & WebSockets ile Token Akışı)

Real-Time Streaming: Server-Sent Events (SSE), Project Reactor Flux & WebSocket Delivery

🤖 AI Mimarisi & Veri Akış Şeması

🤖 AI Architecture & Flow



💡 Aptala Anlatım (ELI5 Metaforu)

💡 ELI5 Metaphor

🇹🇷 TÜRKÇE (ELI5)

Bir restorana gittiğinizde aşçının tüm 5 çeşidin pişmesini 45 dakika bekleyip hepsini birden soğuk getirmesini mi istersiniz, yoksa çorbanız hazır olunca hemen masanıza gelmesini mi? Streaming çorbadır! Bir LLM'in 500 kelimelik bir makaleyi tamamlaması 10 saniye sürebilir. Eğer 10 saniye boyunca kullanıcıya boş bir dönen yükleme tekerleği gösterirseniz kullanıcı sıkılıp sayfayı kapatır. Streaming ile ilk kelime 250 milisaniyede ekrana düşer; kullanıcı okumaya başlarken model arkadan kelimeleri akıtmaya devam eder!

🇬🇧 ENGLISH (ELI5)

When ordering a 5-course dinner, you don't want the kitchen to hold back appetizers for 45 minutes until the dessert is baked. You want hot soup served immediately! Standard LLM inference takes 5-15 seconds to synthesize long paragraphs. Forcing users to stare at a frozen spinner ruins user retention. With Server-Sent Events (SSE) streaming, the Time-to-First-Token (TTFT) drops to 250ms. The user begins reading immediately while subsequent tokens stream in real time!

🔍 MAANG Seviyesi Teknik Derinlik

🇹🇷 MAANG DERİNLEMESİNE ANALİZ

Reaktif Streaming Mekanizması: 1) Server-Sent Events (SSE - `text/event-stream`): Tek yönlü, HTTP tabanlı hafif bir protokoldür. WebSockets'a göre firewall ve load balancer'lardan çok daha rahat geçer. 2) Spring WebFlux & Project Reactor (`Flux\<String>`): Gelen her token bir reaktif sinyaldir (`onNext`). Bellekte tamponlanmadan doğrudan istemciye fırlatılır. 3) TTFT vs Toplam Süre: Toplam yanıt süresi aynı kalsa bile TTFT'nin 300ms'ye inmesi kullanıcının algıladığı gecikmeyi (Perceived Latency) sıfıra indirir.

🔍 MAANG-Level Technical Deep-Dive

🇬🇧 MAANG TECHNICAL DEEP-DIVE

Reactive Streaming Internals: 1) Protocol Choice: Server-Sent Events (`text/event-stream`) is preferred over WebSockets for text delivery due to native HTTP/2 multiplexing, automatic reconnects, and standard proxy compatibility. 2) Non-Blocking Backpressure: Spring AI's `.stream()` exposes a Reactive `Flux\<String>`. Tokens emitted over the chunked HTTP connection flow downstream without blocking carrier threads. 3) Perceived Latency Metrics: While total completion time remains constant, dropping TTFT below human reading speed (<300ms) creates an instantaneous user experience.

⚡ Java 25, Spring AI & LangChain4j Kodu

⚡ Java 25 & OpenAI Implementation

```java
// Java 25 & Spring AI: Controller Katmanında Reactive SSE Streaming
import org.springframework.ai.chat.client.ChatClient;
import org.springframework.http.MediaType;
import org.springframework.web.bind.annotation.GetMapping;
import org.springframework.web.bind.annotation.RequestParam;
import org.springframework.web.bind.annotation.RestController;
import reactor.core.publisher.Flux;

@RestController
public class StreamingChatController {
    private final ChatClient chatClient;

    public StreamingChatController(ChatClient.Builder builder) {
        this.chatClient = builder.build();
    }

    // Server-Sent Events (SSE) ile token bazlı gerçek zamanlı yayın
    @GetMapping(value = "/api/chat/stream", produces = MediaType.TEXT_EVENT_STREAM_VALUE)
    public Flux<String> streamChat(@RequestParam String prompt) {
        return chatClient.prompt()
            .user(prompt)
            .stream()
            .content(); // Her token geldikçe istemciye akar!
    }
}
```

⚠️ Halüsinasyon, Güvenlik & Mülakat Tuzağı

🇹🇷 MÜLAKAT TUZAĞI VE HALÜSİNASYON

Kritik Darboğaz: HTTP/1.1 kullanan eski proxy veya API Gateway'ler yanıtı istemciye göndermeden önce tamponlayabilir (Buffering). Streaming'in çalışması için Nginx/Envoy yapılandırmasında `proxy_buffering off;` yapılmalı veya HTTP/2 aktif edilmelidir!

⚠️ Hallucination & Interview Trap

🇬🇧 INTERVIEW TRAP & HALLUCINATION RISK

Infrastructure bottleneck: Reverse proxies (Nginx, Envoy, AWS ALB) often buffer responses by default, breaking real-time token delivery. You must explicitly set `proxy_buffering off;` and enable chunked transfer encoding.

🎯 Mülakatta Hatırlanacak Altın Çıkarımlar

• Streaming, kullanıcı deneyimini (UX) ve algılanan hızı (TTFT) kurtaran en kritik tekniktir.

• Server-Sent Events (SSE), metin akışı için WebSockets'tan çok daha hafif ve basittir.

• Ters proxy ve gateway'lerde response buffering kesinlikle kapatılmalıdır.

🎯 Key Takeaways for the Interview

• Streaming is the single most vital pattern to optimize perceived latency and TTFT.

• SSE provides a lighter, HTTP-native alternative to WebSockets for unidirectional token streams.

• Response buffering must be disabled on ingress proxies to prevent token batching.