13

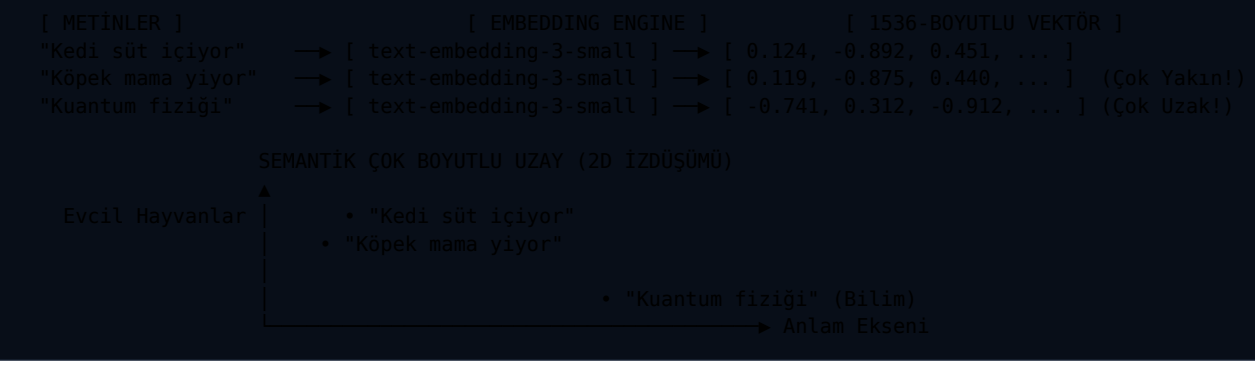
BÖLÜM: VEKTÖRLER, EMBEDDING'LER VE VEKTÖR VERITABANLARI | MODULE: VECTORS, EMBEDDINGS & VECTOR DATABASE ARCHITECTURE

Embedding Nedir? Metinlerin Çok Boyutlu Matematiksel Haritası

Demystifying Embeddings: Mapping Semantic Meaning into Dense Vector Space

🤖 AI Mimarisi & Veri Akış Şeması

🤖 AI Architecture & Flow



💡 Aptala Anlatım (ELI5 Metaforu)

💡 ELI5 Metaphor

🇹🇷 TÜRKÇE (ELI5)

Bir kütüphanedeki kitapları sadece adına göre sıralarsanız, 'Kedi Bakımı' ile 'Köpek Eğitimi' kitapları farklı raflara düşer. Ama kitapları konusuna göre 3 boyutlu bir haritada yerleştirirseniz: Birinci eksen 'Hayvan Sevgisi', ikinci eksen 'Yemek', üçüncü eksen 'Bilim' olsun. Kedi ve köpek kitapları haritada yan yana dururken, 'Kuantum Fiziği' odanın öbür ucuna uçar! İşte Embedding tam olarak budur: Bilgisayarın kelimelerin anlamını anlayabilmesi için her cümleye 1536 adet koordinat sayısı (Vektör) vermesidir!

🇬🇧 ENGLISH (ELI5)

Alphabetical library sorting places 'Cat Nutrition' and 'Dog Training' far apart under C and D. Now imagine placing books in a 3D coordinate room where Axis-X is 'Pet Care', Axis-Y is 'Dietary', and Axis-Z is 'Astrophysics'. Pet books cluster closely together, while 'Quantum Mechanics' sits on the opposite wall! That is an Embedding: a neural transformation converting unstructured human prose into a dense array of floating-point coordinates (1,536 dimensions) where semantic proximity equals geometric proximity!

🔍 MAANG Seviyesi Teknik Derinlik

🇹🇷 MAANG DERİNLEMESİNE ANALİZ

Embedding Modellerinin Teknik Detayları: 1) Boyutluluk (Dimensionality): OpenAI `text-embedding-3-small` 1536 boyutlu, `text-embedding-3-large` ise 3072 boyutlu vektörler üretir. Boyut arttıkça anlam hassasiyeti artar ancak depolama ve RAM maliyeti katlanır. 2) Matryoshka Embeddings: OpenAI'ın v3 modelleri, Rus matruşka bebekleri gibi ilk 512 boyutu alıp geri kalanını kırpmanıza (Truncation) izin verir; doğruluk %98 korunurken veritabanı boyutu %66 küçülür! 3) Normalizasyon: OpenAI vektörleri birim uzunluktadır (||v|| = 1); bu sayede pahalı Cosine Similarity yerine süper hızlı Dot Product (İç Çarpım) kullanılabilir.

🔍 MAANG-Level Technical Deep-Dive

🇬🇧 MAANG TECHNICAL DEEP-DIVE

Embedding Mathematics and Economics: 1) Dense Vector Topology: `text-embedding-3-small` outputs 1,536-dimensional float32 arrays (6KB per vector). `text-embedding-3-large` scales to 3,072 dimensions for subtle multi-domain nuances. 2) Matryoshka Representation Learning (MRL): Modern v3 embeddings allow truncation to lower dimensions (e.g. 512 or 256) while retaining >95% retrieval accuracy, slashing RAM and storage footprint by 66%. 3) Unit Normalization: Vectors are pre-normalized to unit magnitude (L2 norm = 1.0). Consequently, Cosine Distance simplifies mathematically to a raw Dot Product (u · v), reducing CPU vector search cycles.

⚡ Java 25, Spring AI & LangChain4j Kodu

⚡ Java 25 & OpenAI Implementation

```java
// Java 25 & Spring AI: Metinleri Vektör Embedding'e Dönüştürme
import org.springframework.ai.embedding.EmbeddingModel;
import java.util.List;

public class EmbeddingGeneratorService {
    private final EmbeddingModel embeddingModel;

    public EmbeddingGeneratorService(EmbeddingModel embeddingModel) {
        this.embeddingModel = embeddingModel;
    }

    public float[] generateVector(String text) {
        // OpenAI text-embedding-3-small çağrısı yapar ve 1536 float döner
        return embeddingModel.embed(text);
    }

    public List<float[]> batchEmbed(List<String> documents) {
        return embeddingModel.embed(documents);
    }
}
```

⚠️ Halüsinasyon, Güvenlik & Mülakat Tuzağı

⚠️ Hallucination & Interview Trap

🇹🇷 MÜLAKAT TUZAĞI VE HALÜSİNASYON

Ölümcül Hata: Dokümanları `text-embedding-3-small` (1536 boyut) ile indeksleyip, arama yaparken sorguyu `text-embedding-3-large` (3072 boyut) veya Cohere ile vektörleştiremezsiniz! İndeksleme ve sorgulama modelleri BİREBİR AYNI model ve boyut olmak zorundadır.

🇬🇧 INTERVIEW TRAP & HALLUCINATION RISK

Catastrophic error: Searching an index embedded with `text-embedding-3-small` using queries embedded via `text-embedding-3-large` or HuggingFace. Vector dimensions and semantic manifolds must match 100% identically across ingestion and query pipelines.

🎯 Mülakatta Hatırlanacak Altın Çıkarımlar

• Embedding, metinlerin anlamsal özünü çok boyutlu koordinat sayılarına dönüştürür.

• Benzer anlama gelen cümleler vektör uzayında geometrik olarak birbirine çok yakındır.

• Matryoshka boyutsallık kırpma, doğruluktan ödün vermeden RAM maliyetini %66 düşürür.

🎯 Key Takeaways for the Interview

• Embeddings compress semantic human intent into dense high-dimensional vectors.

• Semantically related sentences cluster tightly in vector space.

• Matryoshka representation learning allows truncation to slash vector memory spend by 66%.