17

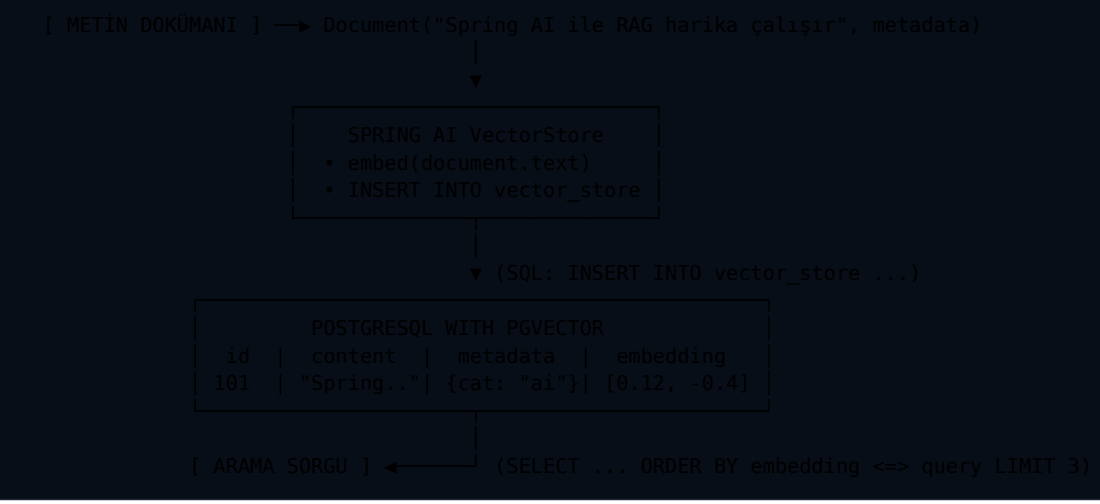
BÖLÜM: VEKTÖRLER, EMBEDDING'LER VE VEKTÖR VERITABANLARI | MODULE: VECTORS, EMBEDDINGS & VECTOR DATABASE ARCHITECTURE

Spring AI VectorStore: PostgreSQL pgvector Entegrasyonu ve Benzerlik Araması

Spring AI VectorStore: PostgreSQL pgvector Integration & Similarity Search

🤖 AI Mimarisi & Veri Akış Şeması

🤖 AI Architecture & Flow



💡 Aptala Anlatım (ELI5 Metaforu)

💡 ELI5 Metaphor

🇹🇷 TÜRKÇE (ELI5)

Elinizde binlerce kartvizit olduğunu düşünün. Normalde bir kartviziti bulmak için adına bakarsınız. Spring AI'ın `VectorStore`'u ise kartvizitlerin arkasına görünmez bir manyetik çip yapıştırır. Siz 'Bana yapay zekadan anlayan bir avukat bul' dediğinizde, elinize bir mıknatıs alır ve kutunun üstünde gezdirirsiniz; aradığınız konsepte en yakın 3 kartvizit 'ŞLAAAP' diye mıknatısa yapışır! Spring AI tüm bu mıknatıs (vektör) işlerini sizin yerinize tek satır kodla yönetir!

🇬🇧 ENGLISH (ELI5)

Imagine a shoebox filled with 5,000 business cards. Spring AI's `VectorStore` attaches a semantic magnet to every card. When you query: 'Find me an attorney who specializes in international cloud compliance', you don't grep for exact keywords. You wave a query magnet over the box, and the 3 cards with the closest semantic magnetic polarity instantly snap onto your hand! Spring AI orchestrates the embedding, SQL insertion, and similarity queries behind a single unified interface!

🔍 MAANG Seviyesi Teknik Derinlik

🇹🇷 MAANG DERİNLEMESİNE ANALİZ

Spring AI pgvector Entegrasyon Mekanizması: 1) Tablo Yapısı: `vector_store` tablosunda `id (UUID)`, `content (TEXT)`, `metadata (JSONB)` ve `embedding (vector(1536))` sütunları yer alır. 2) SearchRequest: `SearchRequest.query(...).withTopK(5).withSimilarityThreshold(0.75)` zinciri ile benzerlik eşiği ve sonuç sayısı ayarlanır. 3) Metadata Filtering: `withFilterExpression("category == 'finance' && year >= 2024")` ifadesi, SQL WHERE koşuluna dönüştürülerek vektör aramasından önce veya sonra (Pre/Post-filtering) işletilir.

🔍 MAANG-Level Technical Deep-Dive

🇬🇧 MAANG TECHNICAL DEEP-DIVE

Spring AI pgvector Architecture: 1) Schema Definition: Operates against standard tables hosting `id (UUID)`, `content (text)`, `metadata (jsonb)`, and `embedding (vector(1536))`. 2) SearchRequest: Fluent abstraction configuring `query()`, `topK()`, and `similarityThreshold()` (filtering out vectors with cosine similarity below a cutoff). 3) Native SQL Dialect Generation: Translates filter expressions into parameterized SQL WHERE clauses (`metadata->>'category' = 'finance'`), avoiding costly post-query in-memory filtering.

⚡ Java 25, Spring AI & LangChain4j Kodu

⚡ Java 25 & OpenAI Implementation

```java
// Java 25 & Spring AI: pgvector VectorStore ile Benzerlik Araması
import org.springframework.ai.document.Document;
import org.springframework.ai.vectorstore.VectorStore;
import org.springframework.ai.vectorstore.SearchRequest;
import java.util.List;
import java.util.Map;

public class KnowledgeBaseService {
    private final VectorStore vectorStore;

    public KnowledgeBaseService(VectorStore vectorStore) {
        this.vectorStore = vectorStore;
    }

    public void ingestDocument(String docId, String text, String department) {
        var document = new Document(docId, text, Map.of("department", department));
        vectorStore.add(List.of(document)); // Otomatik embed edilir ve pgvector'e yazılır!
    }

    public List<Document> searchRelevantKnowledge(String query, String department) {
        return vectorStore.similaritySearch(
            SearchRequest.builder()
                .query(query)
                .topK(3)
                .similarityThreshold(0.70)
                .filterExpression("department == '" + department + "'")
                .build()
        );
    }
}
```

⚠️ Halüsinasyon, Güvenlik & Mülakat Tuzağı

🇹🇷 MÜLAKAT TUZAĞI VE HALÜSİNASYON

Performans Darboğazı: `similarityThreshold` belirtmezseniz, aradığınız konuyla uzaktan yakından ALAKASI OLMAYAN dokümanlar bile ilk 3 sırada gelerek modelin bağlamını kirletir ve halüsinasyona yol açar! Daima makul bir eşik (ör. 0.70+) belirleyin.

⚠️ Hallucination & Interview Trap

🇬🇧 INTERVIEW TRAP & HALLUCINATION RISK

Retrieval pitfall: Querying without a `similarityThreshold` forces the vector store to return the top K nearest neighbors even if their similarity score is abysmal (e.g. 0.20), poisoning the prompt context with irrelevant garbage.

🎯 Mülakatta Hatırlanacak Altın Çıkarımlar

- Spring AI VectorStore, doküman yükleme ve vektör aramasını tekilleştiren bir SPI'dır.
- Metadata filtreleme, alakasız dokümanları SQL seviyesinde eleyerek arama doğruluğunu artırır.
- Benzerlik eşiği (Similarity Threshold) halüsinasyonu önlemede ilk savunma hattıdır.

🎯 Key Takeaways for the Interview

- Spring AI VectorStore unifies document ingestion, embedding, and ANN retrieval behind a clean SPI.
- Metadata filtering at the database layer drastically improves search relevance and speed.
- A well-calibrated similarity threshold is your first line of defense against hallucinations.