20

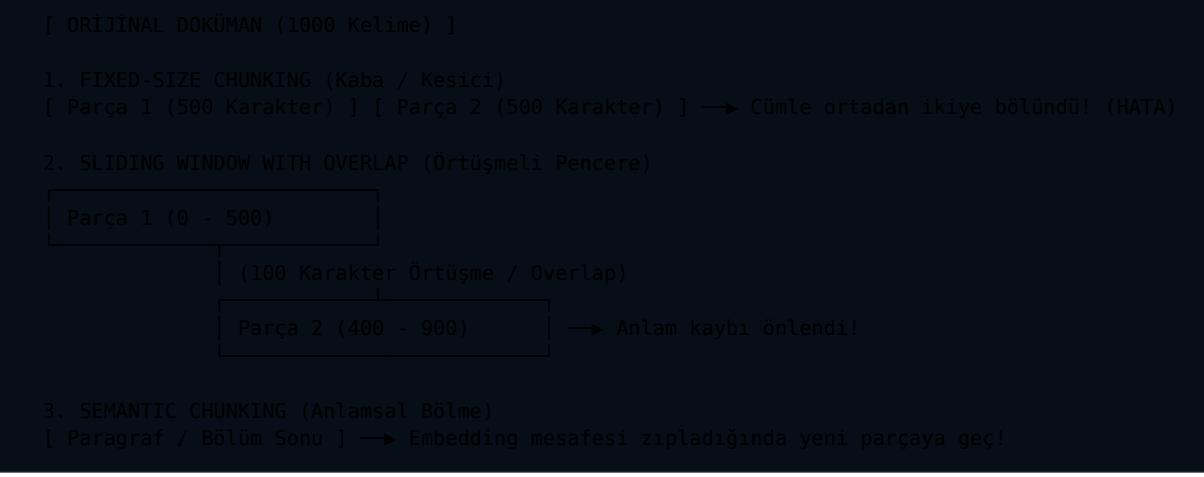
BÖLÜM: ÜRETIM SEVIYESINDE RAG: TEMELLER, CHUNKING & ETL | MODULE: PRODUCTION RAG CORE: FUNDAMENTALS, CHUNKING & INGESTION PIPELINES

Metin Parçalama (Chunking) Stratejileri: Fixed Size, Sliding Window & Semantic

Chunking Strategies: Fixed-Size, Sliding Window, Recursive & Semantic Splitting

🤖 AI Mimarisi & Veri Akış Şeması

🤖 AI Architecture & Flow



💡 Aptala Anlatım (ELI5 Metaforu)

💡 ELI5 Metaphor

🇹🇷 TÜRKÇE (ELI5)

Koca bir karpuzu tek lokmada yiyemezsiniz; dilimlemeniz gerekir. Ama karpuzu gözünüz kapalı bıçakla rastgele keserseniz (Fixed Size), çekirdekler dağılır ve meyve ziyan olur. Akıllı bir şef karpuzu doğal dilim çizgilerinden keser (Semantic Chunking). Metin parçalama da böyledir: Bir kitabı 500'er harflik kör bloklara bölerseniz cümlenin yarısı birinci parçada, yarısı ikinci parçada kalır ve anlam yok olur! Parçaların ucunu hafifçe birbirinin üstüne bindirirseniz (Overlap), anlam bütünlüğü korunur!

🇬🇧 ENGLISH (ELI5)

You can't swallow a whole watermelon; you must slice it. Blindly hacking it with a machete every 4 inches cuts across seeds and crushes the fruit (Fixed-Size Chunking). An expert chef cuts along the natural rind segments (Semantic Chunking). If you chop text blindly by character counts, sentences fracture mid-thought. By introducing a 10-20% Sliding Window Overlap, the trailing context of Chunk A bridges smoothly into Chunk B, preserving pronoun and causal coherence!

🔍 MAANG Seviyesi Teknik Derinlik

🇹🇷 MAANG DERİNLEMESİNE ANALİZ

Chunking Stratejileri ve Trade-Off Analizi: 1) Fixed-Size with Overlap: En yaygın başlangıçtır (ör. 512 token chunk size, 50 token overlap). Hızlıdır ancak anlamsal sınırları (başlıklar, paragraflar) gözetmez. 2) Recursive Character Splitting: Önce çift satır başlarına (\n\n), sonra tek satırlara (\n), sonra noktalara (.) bakar; cümleyi asla ortadan bölmez. 3) Semantic Chunking: Cümleleri tek tek embed eder. Ardışık iki cümle arasındaki Cosine mesafesi belirli bir eşiği (ör. 0.3) aştığında yeni bir konuya geçildiğini anlar ve oradan keser. Hesaplama maliyeti yüksektir ancak arama kalitesi zirvedir.

🔍 MAANG-Level Technical Deep-Dive

🇬🇧 MAANG TECHNICAL DEEP-DIVE

Chunking Engineering & Trade-Offs: 1) Fixed-Size with Overlap: Slices text into uniform token counts (e.g. 500 tokens with 50-token stride). Computationally cheap ($O(N)$), but ignores natural semantic paragraph boundaries. 2) Recursive Hierarchical Splitting: The industry standard. Cascades through separators (\n\n -> \n -> . ->), preserving paragraph and sentence integrity. 3) Semantic Splitting: Computes pairwise embedding distances across adjacent sentences; splits when cosine distance spikes past a percentile threshold, signaling a topic transition.

⚡ Java 25, Spring AI & LangChain4j Kodu

⚡ Java 25 & OpenAI Implementation

```java
// Java 25 & LangChain4j: Recursive ve Örtüşmeli (Overlap) Metin Parçalama
import dev.langchain4j.data.document.Document;
import dev.langchain4j.data.document.splitter.DocumentSplitters;
import dev.langchain4j.data.segment.TextSegment;
import java.util.List;

public class ChunkingPipeline {
    public static List<TextSegment> splitDocumentRecursively(String rawContent) {
        var document = Document.from(rawContent);

        // Maksimum 300 token parça boyutu, 40 token örtüşme (overlap)
        var splitter = DocumentSplitters.recursive(
            300,  // maxSegmentSizeInTokens
            40    // maxOverlapSizeInTokens
        );

        return splitter.split(document);
    }
}

void main() {
    String policy = """
        Bölüm 1: Uzaktan Çalışma Politikası.
        Çalışanlar haftada 3 gün evden çalışabilir.
        Evden çalışma günlerinde mesai saatlerine tam riayet esastır.

        Bölüm 2: Donanım Desteği.
        Şirket her çalışana ergonomik sandalye ve monitör bütçesi sağlar.
        """;

    List<TextSegment> chunks = ChunkingPipeline.splitDocumentRecursively(policy);
    IO.println("Oluşturulan Toplam Parça Sayısı: " + chunks.size());
    for (int i = 0; i < chunks.size(); i++) {
        IO.println("--- Chunk #" + (i + 1) + " ---");
        IO.println(chunks.get(i).text().trim());
    }
}
```

⚠️ Halüsinasyon, Güvenlik & Mülakat Tuzağı

🇹🇷 MÜLAKAT TUZAĞI VE HALÜSİNASYON

Parça Boyutu İkilemi (Chunk Size Dilemma): Chunk çok küçük olursa (ör. 50 token), arama çok isabetli olur ama model soruyu yanıtlamak için gereken çevre bağlamı bulamaz. Chunk çok büyük olursa (ör. 2000 token), alakasız konular araya girer ve embedding kalitesi sulanır (Semantic Dilution). İdeal aralık çoğu metin için 300-600 tokendir.

⚠️ Hallucination & Interview Trap

🇬🇧 INTERVIEW TRAP & HALLUCINATION RISK

The Chunk Size Dilemma: Chunks that are too small (50 tokens) achieve high retrieval precision but lack sufficient contextual breadth to answer complex questions. Chunks that are too large (2,000 tokens) suffer from semantic dilution, washing out specific facts in dense vector averages.

🎯 Mülakatta Hatırlanacak Altın Çıkarımlar

- Overlap (Örtüşme), cümlelerin ortadan bölünmesini ve anlam kaybını önler.
- Recursive Character Splitting, pratik üretim sistemlerinin vazgeçilmez standardıdır.
- İdeal parça boyutu 300-600 token civarındadır; amaca göre ayarlanmalıdır.

🎯 Key Takeaways for the Interview

- Overlap maintains narrative continuity across adjacent text segments.
- Recursive splitting respects paragraphs and sentence boundaries before character limits.
- Optimal production chunk sizes typically range between 300 and 600 tokens.