30

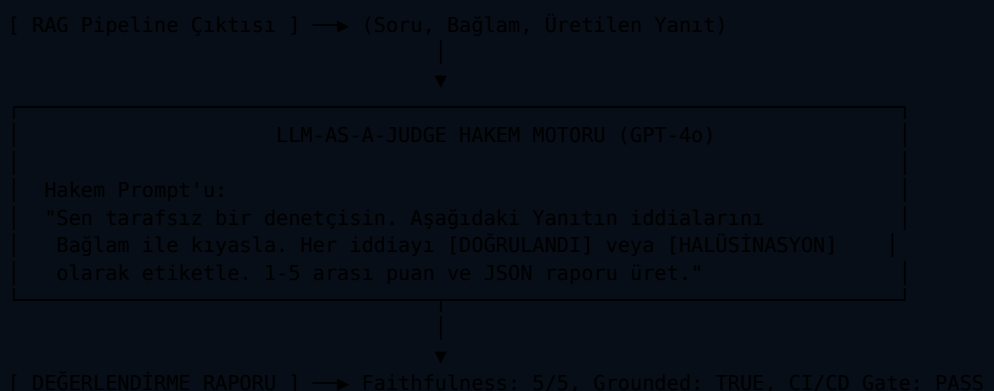
BÖLÜM: İLERI DÜZEY RAG (ADVANCED RAG) & BILGI GETIRME OPTIMIZASYONU | MODULE: ADVANCED RAG & INFORMATION RETRIEVAL OPTIMIZATION

RAG Triad Otomasyonu: RAGAS Metodolojisi & LLM-as-a-Judge Mimarisi

Automated RAG Evaluation: RAGAS Framework & Implementing LLM-as-a-Judge

🤖 AI Mimarisi & Veri Akış Şeması

🤖 AI Architecture & Flow



💡 Aptala Anlatım (ELI5 Metaforu)

💡 ELI5 Metaphor

🇹🇷 TÜRKÇE (ELI5)

Bir okulda 10.000 öğrencinin yazdığı kompozisyonları tek bir öğretmenin sabahlara kadar tek tek okuyup puanlaması imkansızdır (İnsanla değerlendirme çok yavaştır). Bunun yerine kıdemli bir başöğretmene (LLM-as-a-Judge) bir puanlama anahtarı verirsiniz: 'Şu 3 kurala bak, 1 ile 5 arasında not ver, nerede hata varsa altına yaz.' Başöğretmen her gece tüm ödevleri inceler ve sabah not çizelgesini masanıza koyar! LLM-as-a-Judge, yapay zekayı yapay zekaya denetleterek sistem kalitesini her kod gönderildiğinde (CI/CD) otomatik ölçmektir!

🇬🇧 ENGLISH (ELI5)

Evaluating 100,000 production customer responses cannot be done manually by human reviewers (human annotation is slow and unscalable). Instead, you employ an impartial Senior Inspector model (LLM-as-a-Judge) armed with an invariant grading rubric: 'Deconstruct the response into individual claims. Cross-verify each claim against the retrieved snippet. Output a structured JSON audit with a score from 1 to 5.' LLM-as-a-Judge runs automatically inside your CI/CD test suite on every pull request!

🔍 MAANG Seviyesi Teknik Derinlik

🇹🇷 MAANG DERİNLEMESİNE ANALİZ

LLM-as-a-Judge Mimarisi ve İstatistiki Yanlılıklar: 1) Hakem Önyargıları (Biases): a) Position Bias (İlk seçeneği üstün tutma). b) Verbosity Bias (Uzun ve süslü yanıtları daha kaliteli sanma). c) Self-Enhancement Bias (Modelin kendi ürettiği metinlere daha yüksek puan vermesi). 2) İki Taraflı Değerlendirme (Pairwise Evaluation with Swap): Seçeneklerin sırası ters çevrilerek hakeme iki kez sorulur; sadece iki seferde de aynı karar çıkarsa puan geçerli sayılır. 3) CI/CD Entegrasyonu: GitHub Actions üzerinde her PR açıldığında 50 adet altın soru (Gold Evaluation Dataset) test edilir; sadakat skoru %95'in altına düşerse PR kilitlenir!

🔍 MAANG-Level Technical Deep-Dive

🇬🇧 MAANG TECHNICAL DEEP-DIVE

LLM-as-a-Judge Vulnerabilities & CI/CD Gating: 1) Cognitive Judge Biases: a) Verbosity Bias: Models favor longer, eloquently worded responses regardless of precision. b) Position Bias: Predisposition to score Option A higher than Option B in pairwise tests. Countermeasure: execute bidirectional swaps (A/B and B/A). c) Self-Preference Bias: GPT-4 exhibits affinity for GPT-generated prose over Claude or Llama. 2) CI/CD Automation: Run automated evaluation pipelines against a fixed 100-question Golden Dataset on every pull request. If regression drops Faithfulness below 95%, the deployment pipeline aborts.

⚡ Java 25, Spring AI & LangChain4j Kodu

⚡ Java 25 & OpenAI Implementation

```java
// Java 25 & Spring AI: LLM-as-a-Judge ile Otomatik RAG Hakem Servisi
import org.springframework.ai.chat.client.ChatClient;

public class RagJudgeEvaluator {
    private final ChatClient judgeChatClient;

    public record EvaluationVerdict(double faithfulnessScore, String critique, boolean passed) {}

    public RagJudgeEvaluator(ChatClient.Builder builder) {
        this.judgeChatClient = builder.build();
    }

    public EvaluationVerdict auditRagResponse(String query, String context, String generatedAnswer) {
        return judgeChatClient.prompt()
            .system("""
                Sen MAANG seviyesinde katı bir yapay zeka denetçisisin.
                Görevin: Verilen Yanıt'ın SADECE ve SADECE Bağlam'daki bilgilere dayanıp dayanmadığını
doğrulamak.
                Eğer yanıtta bağlamda geçmeyen tek bir iddia bile varsa faithfulnessScore < 0.50
olmalı ve passed = false dönmelidir.
                """)
            .user(u -> u.text("""
                SORU: {query}
                BAĞLAM: {context}
                ÜRETİLEN YANIT: {answer}
                """)
                .param("query", query)
                .param("context", context)
                .param("answer", generatedAnswer))
            .call()
            .entity(EvaluationVerdict.class);
    }
}
```

⚠️ Halüsinasyon, Güvenlik & Mülakat Tuzağı

🇹🇷 MÜLAKAT TUZAĞI VE HALÜSİNASYON

Hakem Modeli Kuralı: Küçük modeller (GPT-4o-mini) karmaşık mantıksal denetimlerde hakemlik yapamaz; ince halüsinasyonları gözden kaçırır! Hakem modeli olarak DAİMA en zeki amiral gemisi model (GPT-4o veya o1) kullanılmalıdır.

⚠️ Hallucination & Interview Trap

🇬🇧 INTERVIEW TRAP & HALLUCINATION RISK

Judge capacity requirement: Never use miniature tier models (e.g. gpt-4o-mini) as judges. Sub-parameter models lack the cognitive reasoning required to identify subtle factual inconsistencies. The Judge model must strictly be Tier-1 (GPT-4o, Claude 3.5 Sonnet, or o1).

🎯 Mülakatta Hatırlanacak Altın Çıkarımlar

- LLM-as-a-Judge, yüz binlerce RAG çıktısını otomatik ve ölçeklenebilir biçimde denetler.
- Hakem önyargılarını (Verbosity ve Position bias) kırmak için çift yönlü testler şarttır.
- Altın test veri setleri (Golden Datasets) ile CI/CD pipeline'larında regresyonlar engellenir.

🎯 Key Takeaways for the Interview

- LLM-as-a-Judge scales quality assurance across millions of RAG interactions cost-effectively.
- Counteract verbosity and position biases via pairwise order swaps.
- Embedding evaluation suites in CI/CD ensures new prompts do not cause quality regressions.