44

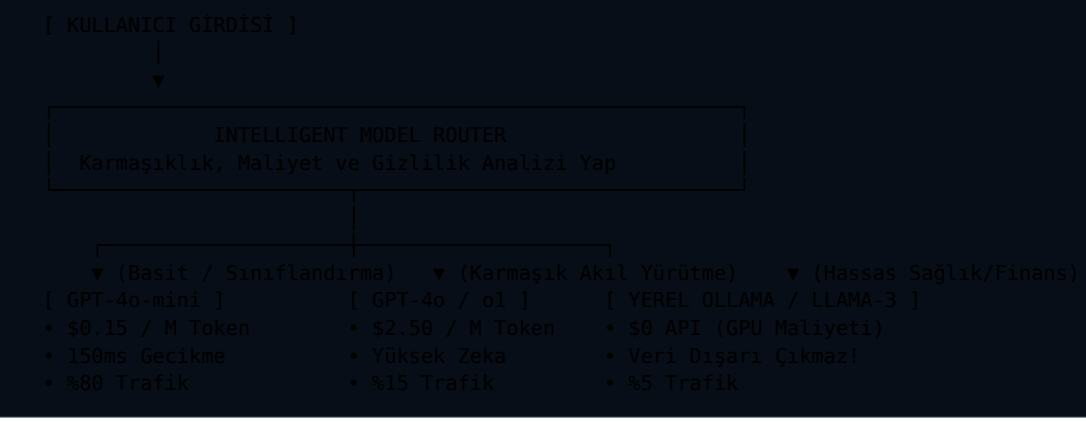
BÖLÜM: LLM PERFORMANSI, CACHING, MALIYET & GECIKME OPTIMIZASYONU | MODULE: LLM PERFORMANCE ENGINEERING: CACHING, MODEL ROUTING & COST OPTIMIZATION

Dinamik Model Yönlendirme (Model Routing: GPT-4o vs GPT-4o-mini vs Yerel)

Dynamic Model Routing: Cascading between GPT-4o, GPT-4o-mini & On-Prem LLMs

🤖 AI Mimarisi & Veri Akış Şeması

🤖 AI Architecture & Flow



💡 Aptala Anlatım (ELI5 Metaforu)

💡 ELI5 Metaphor

🇹🇷 TÜRKÇE (ELI5)

Bakkaldan bir ekmek almak için evin garajındaki 10 tonluk devasa vinci çalıştırmazsınız; bisiklete binip gidersiniz (Hızlı, ucuz, pratik)! Ama koca bir inşaat demiri taşıyacaksanız vinç zorunludur. Model Yönlendirme (Routing) tam olarak budur: Kullanıcı sadece 'Merhaba, nasılsın?' dediğinde veya basit bir e-postayı sınıflandırırken en pahalı amiral gemisi modeli (GPT-4o) çağırmak para yakmaktır! Küçük ve ışık hızında çalışan ucuz bir model (GPT-4o-mini) işi 10 kat daha ucuza halleder. Sadece karmaşık mimari ve analiz gerektiren zor sorularda büyük modeller devreye girer!

🇬🇧 ENGLISH (ELI5)

You don't fire up a 40-ton industrial crane to buy milk from the local grocer; you hop on a bicycle (fast, agile, near-zero cost). But if you are lifting a 20-ton steel bridge girder, the heavy crane is indispensable. Model Routing applies this intelligence to inference: if a user texts 'Hello, help me reset my password', firing up GPT-4o or o1 burns enterprise budget unnecessarily. A lightweight tier model (GPT-4o-mini) resolves the query in 150ms at 1/15th the cost!

🔍 MAANG Seviyesi Teknik Derinlik

🇹🇷 MAANG DERİNLEMESİNE ANALİZ

Model Routing Stratejileri: 1) Kural Tabanlı Yönlendirme (Rule-based): Regex veya keyword analiziyle sınıflandırma soruları doğrudan mini modele yönlendirilir. 2) Embedding Tabanlı Intent Router: Sorgunun embedding'i alınır; önceden etiketlenmiş 'Zor Sorular' kümesine yakınsa büyük modele, 'Kolay Sorular' kümesine yakınsa ucuz modele yönlendirilir. 3) LLM-Cascading (Fällback): Önce ucuz model çağrılır; eğer güven skoru (Confidence / Logprobs) düşükse veya JSON doğrulamasından geçemezse istek otomatik olarak GPT-4o'ya yükseltilir (Escalation).

🔍 MAANG-Level Technical Deep-Dive

🇬🇧 MAANG TECHNICAL DEEP-DIVE

Model Routing Topologies & Cascading: 1) Heuristic & Regex Gateways: Deterministic rule engines routing keyword tasks (intent classification, translation) to miniature models. 2) Semantic Intent Embeddings: Computes embedding proximity against centroid clusters representing task complexity tiers. 3) LLM Cascading & Speculative Routing: Always dispatch to the cheapest model first. If model confidence (log probabilities) or schema validator checks fail, cascade the request upwards to GPT-4o or reasoning models (o1). This hybrid routing typically slashes enterprise LLM bills by 65-80%.

⚡ Java 25, Spring AI & LangChain4j Kodu

⚡ Java 25 & OpenAI Implementation

```
// Java 25: Akıllı Model Yönlendirici (Model Router)
public class IntelligentModelRouter {
    public enum ModelTier { TIER1_EXPENSIVE_GPT4O, TIER2_CHEAP_MINI, TIER3_ONPREM_PRIVATE }

    public static ModelTier routeQuery(String query, boolean containsSensitivePii) {
        if (containsSensitivePii) {
            return ModelTier.TIER3_ONPREM_PRIVATE; // Gizlilik gereği dışarı çıkamaz
        }

        // Basit sınıflandırma ve formatlama işleri için ucuz model
        String lower = query.toLowerCase();
        if (lower.startsWith("sınıflandır") || lower.startsWith("tarihi formatla") || query.length() <
50) {
            return ModelTier.TIER2_CHEAP_MINI;
        }

        // Karmaşık sistem tasarımı, kod ve analiz için büyük model
        return ModelTier.TIER1_EXPENSIVE_GPT4O;
    }
}

void main() {
    IO.println("Sorgu 1 Yönlendirmesi: " + IntelligentModelRouter.routeQuery("Bu metni İngilizceye
çevir: Selam", false));
    IO.println("Sorgu 2 Yönlendirmesi: " + IntelligentModelRouter.routeQuery("Bana çok bölgeli Kafka
mimarisi tasarla", false));
}
```

⚠️ Halüsinasyon, Güvenlik & Mülakat Tuzağı

🇹🇷 MÜLAKAT TUZAĞI VE HALÜSİNASYON

Hata Uyarısı: Hassas kullanıcı verilerini (TC Kimlik, Kredi Kartı, Sağlık Verisi) kontrol etmeden OpenAI gibi genel bulut API'lerine yönlendirmek KVKK ve GDPR cezalarına yol açar. PII tespiti yapıldığında yönlendirici isteği yerel on-prem modellere veya anonimleştiriciye (Data Masking) yönlendirmelidir.

⚠️ Hallucination & Interview Trap

🇬🇧 INTERVIEW TRAP & HALLUCINATION RISK

Compliance vulnerability: Routing raw PII or HIPAA-governed health records directly to third-party public LLM endpoints triggers catastrophic regulatory fines. The router must inspect payloads and shunt sensitive records to on-premise local models or anonymization filters.

🎯 Mülakatta Hatırlanacak Altın Çıkarımlar

• Trafik genelde %80 basit, %20 karmaşık sorulardan oluşur; tek bir model kullanmak israftır.

• Model Routing, kurumsal yapay zeka harcamalarını %60-%80 oranında düşürür.

• Hassas veriler router seviyesinde filtrelenerek yerel modellere yönlendirilmelidir.

🎯 Key Takeaways for the Interview

• Traffic is typically 80% routine and 20% complex; routing to a single model is fiscally irresponsible.

• Intelligent model routing cuts enterprise inference expenditure by 60-80%.

• Sensitive data must be intercepted at the router layer and routed to compliant on-prem models.