45

BÖLÜM: LLM PERFORMANSI, CACHING, MALIYET & GECIKME OPTIMIZASYONU | MODULE: LLM PERFORMANCE ENGINEERING: CACHING, MODEL ROUTING & COST OPTIMIZATION

Streaming Gecikmesi & TTFT (Time to First Token) Optimizasyonu

Latency Engineering: Optimizing TTFT (Time to First Token) & Token Per Second (TPS)

🤖 AI Mimarisi & Veri Akış Şeması

🤖 AI Architecture & Flow



💡 Aptala Anlatım (ELI5 Metaforu)

💡 ELI5 Metaphor

🇹🇷 TÜRKÇE (ELI5)

Bir yarış arabasının iki önemli göstergesi vardır: Sıfırdan 100 km hıza kaç saniyede çıktığı (TTFT - Time to First Token) ve son süratinin kaç km olduğu (TPS - Tokens Per Second). Kullanıcı için en sinir bozucu şey, gaza bastıktan sonra arabanın 5 saniye boyunca hiç tepki vermemesidir! Yapay zekada da kullanıcının ekranda ilk kelimeyi görme süresi (TTFT) 300 milisaniyenin altındaysa, sistem sihirli ve ışık hızında hissettirir. Kelimeler aktığı sürece toplam sürenin 5 saniye sürmesi kimseyi rahatsız etmez!

🇬🇧 ENGLISH (ELI5)

A supercar is benchmarked on two metrics: 0-to-60 acceleration (TTFT - Time to First Token) and top track speed (TPS - Tokens Per Second). For human users, the most excruciating friction is tapping a button and enduring a frozen screen for 5 seconds. If your Time-to-First-Token drops under 300ms, the interface feels instantaneous. As long as text streams smoothly at human reading speed (15-20 TPS), total completion duration is psychologically imperceptible!

🔍 MAANG Seviyesi Teknik Derinlik

🔍 MAANG-Level Technical Deep-Dive

🇹🇷 MAANG DERİNLEMESİNE ANALİZ

Gecikme Anatomisi ve Optimizasyon Teknikleri: 1) TTFT (Time to First Token) Neleri Kapsar?: DNS çözümleme, TLS el sıkışması, Prompt Caching kontrolü ve modelin tüm girdi token'larını tek seferde işleme süresi (Prefill Phase). 2) Prefill Phase vs Decoding Phase: Girdi token sayısı arttıkça (ör. büyük RAG bağlamı) Prefill süresi uzar ve TTFT fırlar! Çözüm: Prompt'u kısa tutmak ve Prompt Caching kullanmaktır. 3) HTTP/2 Multiplexing: Çoklu token akışlarının tek bir TCP bağlantısı üzerinden paralel akıtılması TLS gecikmesini sıfırlar.

🇬🇧 MAANG TECHNICAL DEEP-DIVE

Latency Decomposition & GPU Phase Physics: 1) TTFT Components: Network RTT + TLS handshake + Gateway dispatch + GPU Prefill Phase. 2) The Prefill Bottleneck: Before emitting token 1, the transformer must compute attention keys and values for every prompt token concurrently in memory. A 10,000-token prompt causes a 1,500ms prefill lag! Mitigation: Leverage prompt caching to bypass prefill passes on static prefixes. 3) Generation Phase (Memory-Bound): Generating subsequent tokens is memory-bandwidth bound. Optimizing TPS requires speculative decoding or smaller quantized models.

⚡ Java 25, Spring AI & LangChain4j Kodu

⚡ Java 25 & OpenAI Implementation

```
// Java 25: TTFT ve Token Akış Hızı (TPS) Performans Monitörü
public class LatencyMetricsTracker {
    private final long requestStartNanos;
    private long firstTokenNanos = 0;
    private int tokenCount = 0;

    public LatencyMetricsTracker() {
        this.requestStartNanos = System.nanoTime();
    }

    public synchronized void onTokenReceived() {
        if (firstTokenNanos == 0) {
            firstTokenNanos = System.nanoTime(); // TTFT yakalandı!
        }
        tokenCount++;
    }

    public double getTtftMillis() {
        if (firstTokenNanos == 0) return 0.0;
        return (firstTokenNanos - requestStartNanos) / 1_000_000.0;
    }

    public double getTokensPerSecond() {
        long durationNanos = System.nanoTime() - firstTokenNanos;
        if (durationNanos <= 0 || tokenCount <= 1) return 0.0;
        return (tokenCount - 1) / (durationNanos / 1_000_000_000.0);
    }
}

void main() {
    var tracker = new LatencyMetricsTracker();
    // Simüle edilmiş ilk token gelişi (280ms sonra)
    try { Thread.sleep(280); } catch (Exception e) {}
    tracker.onTokenReceived();

    IO.println("Time to First Token (TTFT): " + String.format("%.2f", tracker.getTtftMillis()) + "
ms");
    IO.println("MAANG Üretim Standardı (<400ms): " + (tracker.getTtftMillis() < 400 ? "✅ BAŞARILI" :
"❌ YAVAŞ"));
}
```

⚠️ Halüsinasyon, Güvenlik & Mülakat Tuzağı

⚠️ Hallucination & Interview Trap

🇹🇷 MÜLAKAT TUZAĞI VE HALÜSİNASYON

Gecikme Tuzağı: İstemciye streaming yaparken araya ağır bir senkron Re-ranker veya JSON validator koyarsanız, streaming başlayamaz ve TTFT saniyelerce ertelenir. Ağır doğrulama gerektiren işlerde streaming değil, asenkron bildirimler kullanılmalıdır.

🇬🇧 INTERVIEW TRAP & HALLUCINATION RISK

Architectural sequencing trap: Inserting blocking post-processors or deep cross-encoders in the path of a streaming pipeline delays the initial token release, defeating the purpose of streaming. Keep the path to first token strictly non-blocking.

🎯 Mülakatta Hatırlanacak Altın Çıkarımlar

• TTFT (Time to First Token), kullanıcının sistem hızını algılamasındaki en kritik metriktir.

• Büyük prompt bağlamları GPU Prefill süresini uzatarak ilk token gecikmesini artırır.

• Prompt Caching, prefill fazını atlayarak TTFT'yi %80'e kadar hızlandırır.

🎯 Key Takeaways for the Interview

• TTFT is the single most decisive factor shaping user perception of application speed.

• Massive prompt contexts inflate GPU prefill duration, spiking TTFT latency.

• Prompt caching bypasses prefill recalculations to accelerate TTFT by up to 80%.