48

BÖLÜM: LLM PERFORMANSI, CACHING, MALIYET & GECIKME OPTIMIZASYONU | MODULE: LLM PERFORMANCE ENGINEERING: CACHING, MODEL ROUTING & COST OPTIMIZATION

Token Budgeting, Sliding Window Truncation ve Maliyet Sınırlandırma

Token Budgeting, Sliding Window Truncation & Cost Bounding Policies

🤖 AI Mimarisi & Veri Akış Şeması

🤖 AI Architecture & Flow



💡 Aptala Anlatım (ELI5 Metaforu)

💡 ELI5 Metaphor

🇹🇷 TÜRKÇE (ELI5)

Tatile çıkarken bavulunuzun havayolu sınırı 20 kilodur (Token Bütçesi). Bavulun içine rastgele eşya fırlatırsanız havaalanında ceza ödersiniz. Akıllı bir yolcu bütçeleme yapar: '5 kilo temel giysiler (Sistem Prompt), 8 kilo iş evrakları (RAG Dokümanları), 2 kilo kişisel eşyalar (Kullanıcı Sorusu) ve 5 kilo da tatilden dönerken alacağım hediyelikler için boş yer bırak (Modelin Yanıt Bütçesi)!' Token bütçeleme tam olarak budur: Modelin sınırları aşmasını ve faturanın patlamasını önceden matematiksel olarak garantilemektir!

🇬🇧 ENGLISH (ELI5)

When boarding a budget flight, your luggage allowance is capped at 20 kilograms (The Token Budget). Tossing random clothes inside incurs steep overweight fees at the gate. A seasoned traveler allocates weight methodically: 5kg for essential clothing (System Prompt), 8kg for work gear (RAG Context), 2kg for toiletries (User Query), leaving a guaranteed 5kg reserve for souvenirs brought home (Completion Token Budget). Token Budgeting calculates and enforces discrete byte-level boundaries before payloads hit the API!

🔍 MAANG Seviyesi Teknik Derinlik

🇹🇷 MAANG DERİNLEMESİNE ANALİZ

Token Bütçeleme Mühendisliği: 1) Hard Capping vs Soft Truncation: Prompt gönderilmeden önce BPE tokenizer ile token sayısı hesaplanır (`tiktoken` veya `JTokkit`). Eğer (Tokens_prompt + MaxTokens_gen > Budget) ise, en eski RAG parçası veya sohbet geçmişi dinamik olarak budanır (FIFO Truncation). 2) Asimetrik Rezervasyon: Yanıt için ayrılan `max_tokens` (veya `max_completion_tokens`) asla kısılmamalıdır; aksi takdirde model cümlesinin tam ortasında kesilir (`finish_reason: length`) ve JSON çıktısı bozulur. 3) Bütçe Alarmı: Günlük harcama limiti aşıldığında PagerDuty/Slack alarmı tetiklenmeli ve API otomatik olarak ucuz modele geçmelidir.

🔍 MAANG-Level Technical Deep-Dive

🇬🇧 MAANG TECHNICAL DEEP-DIVE

Token Bounding Mechanics: 1) Pre-Flight Token Counting: Compute exact token counts locally before network dispatch using high-performance tokenizers (e.g. `JTokkit` for Java). 2) Asymmetric Reservation Protocol: The completion budget must remain strictly reserved; choking completion tokens causes mid-sentence cutoff (`finish_reason: length`), corrupting JSON payloads. 3) Dynamic Context Degradation: If a long query breaches budget, shed the lowest-ranked RAG chunk first, then truncate conversation history, never truncating the core system instructions.

⚡ Java 25, Spring AI & LangChain4j Kodu

⚡ Java 25 & OpenAI Implementation

```
// Java 25: Sıkı Token Bütçe Yöneticisi (Token Budget Enforcer)
public class TokenBudgetEnforcer {
    private final int totalBudget;
    private final int reservedForCompletion;

    public TokenBudgetEnforcer(int totalBudget, int reservedForCompletion) {
        this.totalBudget = totalBudget;
        this.reservedForCompletion = reservedForCompletion;
    }

    public int getAvailablePromptTokens() {
        return totalBudget - reservedForCompletion;
    }

    public boolean validateBudget(int currentPromptTokens) {
        return currentPromptTokens <= getAvailablePromptTokens();
    }
}

void main() {
    var enforcer = new TokenBudgetEnforcer(4096, 1024); // 4096 toplam, 1024 yanıta ayrıldı
    int promptTokens = 2500;

    IO.println("İzin Verilen Maksimum Prompt Token: " + enforcer.getAvailablePromptTokens());
    IO.println("Bütçe Kontrolü (2500 token): " + (enforcer.validateBudget(promptTokens) ? "✅
GEÇERLİ" : "❌ BÜTÇE AŞILDI"));
}
```

⚠️ Halüsinasyon, Güvenlik & Mülakat Tuzağı

🇹🇷 MÜLAKAT TUZAĞI VE HALÜSİNASYON

JSON Bozulma Tuzağı: Modelden JSON beklerken `max_tokens` değerini çok küçük tutarsanız (ör. 100 token), model JSON'ı kapatamadan kesilir (`{"name": "Ahmet", "stat...`) ve Jackson parser JSONSyntaxException patlatır! JSON çıktılarında completion bütçesi daima cömert tutulmalıdır.

⚠️ Hallucination & Interview Trap

🇬🇧 INTERVIEW TRAP & HALLUCINATION RISK

JSON truncation disaster: Constraining `max_tokens` too tightly when expecting structured outputs causes the generation to abort mid-object (`{"status": "SUCC...`), yielding malformed JSON that crashes downstream deserializers. Always provision ample completion headroom.

🎯 Mülakatta Hatırlanacak Altın Çıkarımlar

- Token bütçeleme, beklenmeyen fatura patlamalarını ve bağlam aşımını önler.
- Yanıta ayrılan completion token bütçesi JSON bozulmalarını önlemek için daima korunmalıdır.
- Token sınırına yaklaşıldığında sistem promptu değil, en eski RAG parçaları budanmalıdır.

🎯 Key Takeaways for the Interview

- Token budgeting prevents unexpected billing spikes and context window overflows.
- Completion token reservations must be safeguarded to avoid truncated JSON payloads.
- When shedding tokens, prune low-ranked RAG chunks first, never core system instructions.