57

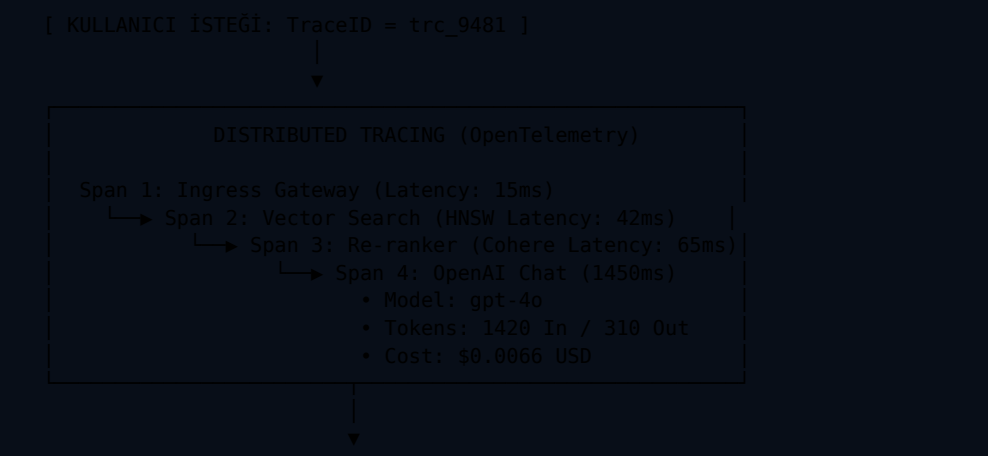
BÖLÜM: AI GÜVENLİĞİ, GÖZLEMLENEBILIRLIK & MAANG MÜLAKAT USTALIĞI | MODULE: AI SECURITY, OBSERVABILITY & THE MAANG INTERVIEW MASTERY RUBRIC

Gözlemlenebilirlik (Observability), Tracing & LLM Metrikleri (OpenTelemetry, Langfuse)

LLM Observability & Tracing: OpenTelemetry, Langfuse & Production Telemetry

🤖 AI Mimarisi & Veri Akış Şeması

🤖 AI Architecture & Flow



💡 Aptala Anlatım (ELI5 Metaforu)

💡 ELI5 Metaphor

🇹🇷 TÜRKÇE (ELI5)

Bir kargo gönderdiğinizde kargo takip numarasını sisteme girersiniz ve kargonun hangi aktarma merkezinde kaç dakika beklediğini adım adım görürsünüz (Tracing). Gözlemlenebilirlik (Observability) yapay zekanın kargo takip sistemidir! Bir kullanıcı 'Uygulama çok yavaşladı' dediğinde, yavaşlığın veritabanında mı, re-ranker'da mı yoksa OpenAI'ın sunucularında mı olduğunu milisaniye hassasiyetiyle ekranınızda görürsünüz. Hangi kullanıcının kaç kuruşluk token harcadığını kuruşu kuruşuna canlı gösterir!

🇬🇧 ENGLISH (ELI5)

When shipping a valuable parcel across the world, a tracking number lets you pinpoint the exact warehouse where the truck is currently idling (Distributed Tracing). LLM Observability is that flight-data recorder for AI pipelines! When a customer complains: 'The assistant is hanging', observability tools like OpenTelemetry and Langfuse visually graph every sub-span: did the vector search take 40ms? Did the reranker take 80ms? Did OpenAI take 2,000ms? It tracks token spend, latency, and hallucination rates in real time!

🔍 MAANG Seviyesi Teknik Derinlik

🇹🇷 MAANG DERİNLEMESİNE ANALİZ

LLM Gözlemlenebilirlik Mimarisi: 1) OpenTelemetry Semantik Konvansiyonları (GenAI Spans): Her LLM çağrısı standart span etiketleriyle donatılır: `gen_ai.system: openai`, `gen_ai.request.model: gpt-4o`, `gen_ai.usage.input_tokens`, `gen_ai.usage.output_tokens`. 2) Tracing & Spans: `TraceId` kullanıcıdan başlar, Spring AI ChatClient üzerinden geçer ve veritabanı sorgusunu sarmalar. 3) Langfuse / Arize Phoenix: LLM'e özel açık kaynak izleme platformlarıdır; kullanıcının verdiği 'Beğen/Beğenme' (Thumbs Up/Down) geri bildirimlerini ilgili `trace_id` ile eşleştirir.

🔍 MAANG-Level Technical Deep-Dive

🇬🇧 MAANG TECHNICAL DEEP-DIVE

OpenTelemetry GenAI Semantic Conventions & Instrumentation: 1) Standardized Attributes: Spans must emit standard OpenTelemetry GenAI metadata (`gen_ai.operation.name`, `gen_ai.request.model`, `gen_ai.usage.prompt_tokens`, `gen_ai.usage.completion_tokens`, `gen_ai.response.finish_reasons`). 2) Distributed Span Hierarchy: Root trace spans originate at the HTTP gateway, bifurcating into child spans for VectorStore ANN search, Cohere Reranking, and OpenAI SSE streams. 3) Feedback Loop Association: Platforms like Langfuse link downstream user sentiment scores (thumbs-up/down) directly to specific prompt span IDs, pinpointing problematic model generations.

⚡ Java 25, Spring AI & LangChain4j Kodu

⚡ Java 25 & OpenAI Implementation

```java
// Java 25: OpenTelemetry Uyumlu LLM Telemetry Metrik Modeli
public record LlmTraceSpan(
    String traceId,
    String modelName,
    long durationMillis,
    int inputTokens,
    int outputTokens,
    double calculatedCostUsd
) {
    public static LlmTraceSpan recordSpan(String traceId, String model, long durationMs, int inTokens,
int outTokens) {
        // GPT-4o maliyet hesabı ($2.50 / $10.00 per 1M)
        double cost = ((inTokens / 1_000_000.0) * 2.50) + ((outTokens / 1_000_000.0) * 10.0);
        return new LlmTraceSpan(traceId, model, durationMs, inTokens, outTokens, cost);
    }
}

void main() {
    var trace = LlmTraceSpan.recordSpan("trc_94812", "gpt-4o", 1250, 1850, 220);
    IO.println("Trace ID: " + trace.traceId());
    IO.println("Model: " + trace.modelName() + " | Toplam Süre: " + trace.durationMillis() + " ms");
    IO.println("Harcanan Token: " + (trace.inputTokens() + trace.outputTokens()) + " (" +
trace.inputTokens() + " in / " + trace.outputTokens() + " out)");
    IO.println("Hesaplanan Maliyet: $" + String.format("%.6f", trace.calculatedCostUsd()));
}
```

⚠️ Halüsinasyon, Güvenlik & Mülakat Tuzağı

🇹🇷 MÜLAKAT TUZAĞI VE HALÜSİNASYON

Gizlilik Uyarısı: Loglama ve Tracing yaparken kullanıcıların özel promptlarını ve şifrelerini DÜZ METİN (Cleartext) olarak log dosyalarına basmayın! Loglar sızdığında veri ihlali cezası doğar. Tracing platformlarına göndermeden önce hassas veriler maskelenmeli veya sadece token sayıları loglanmalıdır.

⚠️ Hallucination & Interview Trap

🇬🇧 INTERVIEW TRAP & HALLUCINATION RISK

Telemetry privacy violation: Blindly logging full prompt and response payloads to centralized tracing tools (Datadog, Langfuse) stores raw customer PII and credentials in log indexes. Always sanitize and redact spans before publishing to telemetry collectors.

🎯 Mülakatta Hatırlanacak Altın Çıkarımlar

- OpenTelemetry GenAI standartları, LLM sistemlerinin izlenebilirliğini tekilleştirir.
- Dağıtık Tracing, gecikmenin nerede yaşandığını (Vektör mü, LLM mi) anında gösterir.
- Canlı maliyet ve token metrikleri izlenmeden hiçbir AI sistemi üretime çıkarılamaz.

🎯 Key Takeaways for the Interview

- OpenTelemetry GenAI semantic conventions standardize LLM observability across tools.
- Distributed tracing pinpoints whether latency bottlenecks stem from vector search or model APIs.
- Inference spend and token velocity must be actively monitored to prevent budget overruns.