58

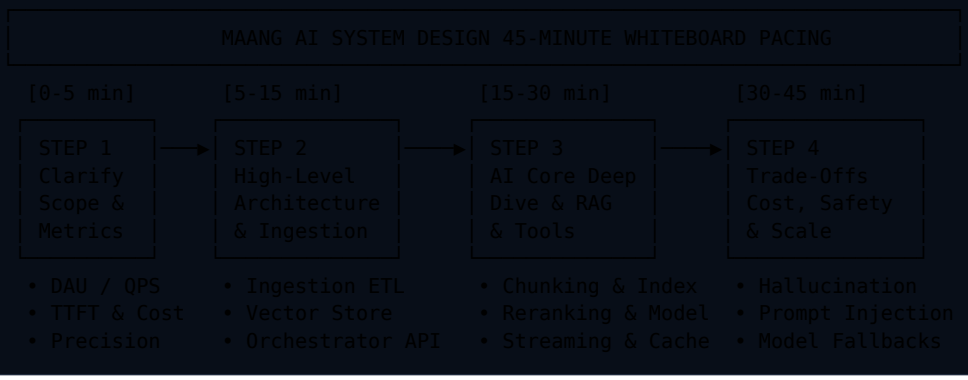
BÖLÜM: AI GÜVENLİĞİ, GÖZLEMLENEBILIRLIK & MAANG MÜLAKAT USTALIĞI | MODULE: AI SECURITY, OBSERVABILITY & THE MAANG INTERVIEW MASTERY RUBRIC

MAANG AI Sistem Tasarımı Mülakatında 45 Dakikalık Zaman Çizelgesi

The 45-Minute MAANG AI System Design Interview Blueprint: Whiteboard Pacing

🤖 AI Mimarisi & Veri Akış Şeması

🤖 AI Architecture & Flow



💡 Aptala Anlatım (ELI5 Metaforu)

💡 ELI5 Metaphor

🇹🇷 TÜRKÇE (ELI5)

45 dakikalık bir MAANG mülakatı Formula 1 yarışına benzer: Pit-stop sürenizi iyi ayarlayamazsanız yarış biter! İlk 5 dakikada hemen tahtaya kutular çizmeye başlarsanız duvara toslarsınız. Önce mülakatçıya sorular sorup yarışı planlarsınız (Scope). Sonra sistemin ana haritasını çizersiniz (High-Level). Ardından asıl uzmanlığınızı gösterip motorun (RAG, Vektörler, Ajanlar) içini açıp incelersiniz (Deep Dive). En son da araba kaza yaparsa ne olacağını (Güvenlik, Hata, Maliyet) anlatıp çizgiyi birinci bitirirsiniz!

🇬🇧 ENGLISH (ELI5)

A 45-minute MAANG system design round is like a Formula 1 Grand Prix: reckless pacing causes a terminal crash. Diving immediately into drawing vector database boxes guarantees immediate rejection. You pace the session systematically: clarify ambiguity and SLA numbers (Step 1), construct the macro-architecture (Step 2), deep-dive into the critical AI engine components (Step 3), and stress-test trade-offs under scale, failure, and adversarial attacks (Step 4)!

🔍 MAANG Seviyesi Teknik Derinlik

🇹🇷 MAANG DERİNLEMESİNE ANALİZ

45 Dakikanın Altın Zaman Yönetimi: 1) Dakika 0-5 (Kapsam & Metrikler): Fonksiyonel (Hangi sorular yanıtlanacak?) ve Non-Fonksiyonel (QPS, TTFT < 300ms, P99 < 2s, Bütçe sınırı, Hallucination < %2). 2) Dakika 5-15 (Yüksek Seviye Mimari): Ingestion Pipeline (Kafka, Tika, Splitter), Vector DB (pgvector/Pinecone), AI Gateway (Spring AI/Java 25) ve Model (GPT-4o). 3) Dakika 15-30 (Derinlemesine İnceleme): Chunking stratejisi (500 token recursive + overlap), Hibrit arama (RRF), Re-ranking ve Tool calling akışı. 4) Dakika 30-45 (Darboğazlar & Staff+ Savunusu): Prompt Caching, HitL onayı, Token budgeting ve Prompt Injection koruması.

🔍 MAANG-Level Technical Deep-Dive

🇬🇧 MAANG TECHNICAL DEEP-DIVE

The 45-Minute Execution Playbook: 1) Min 0-5 (Clarification & SLA Bounds): Functional bounds (domain corpus, languages) vs Non-Functional metrics (1,000 QPS, TTFT < 300ms, target P99 < 1,500ms, cost ceiling $0.005/query, faithfulness >= 98%). 2) Min 5-15 (High-Level Topology): Diagram data ingestion, decoupled vector stores, orchestrator microservices, and client streaming gateways. 3) Min 15-30 (Deep Dive): Drill down into the hardest component: recursive chunking, hybrid dense/sparse indexing, cross-encoder rerankers, and deterministic tool schemas. 4) Min 30-45 (Staff+ Hardening): Address single-points-of-failure, model provider outages (fallback routers), prompt injection, and continuous evaluation in CI/CD.

⚡ Java 25, Spring AI & LangChain4j Kodu

⚡ Java 25 & OpenAI Implementation

```java
// Java 25: MAANG Mülakat Metrikleri ve SLA Sözleşmesi Modeli
public record MaangInterviewSlaContract(
    String systemName,
    int targetQps,
    int maxTtftMillis,
    double maxCostPerQueryUsd,
    double targetFaithfulness
) {
    public static MaangInterviewSlaContract createDefault() {
        return new MaangInterviewSlaContract(
            "Enterprise Knowledge Copilot",
            500,    // 500 QPS zirve trafik
            250,    // TTFT < 250ms
            0.004,  // İstek başı $0.004 bütçe tavanı
            0.98    // %98 Sadakat (Minimum halüsinasyon)
        );
    }
}

void main() {
    var sla = MaangInterviewSlaContract.createDefault();
    IO.println("=== MAANG AI Mülakat Hedef SLA Tablosu ===");
    IO.println("Sistem: " + sla.systemName());
    IO.println("Hedef QPS: " + sla.targetQps() + " req/sec");
    IO.println("Hedef TTFT: " + sla.maxTtftMillis() + " ms");
    IO.println("Maksimum Maliyet: $" + sla.maxCostPerQueryUsd());
    IO.println("Hedef Sadakat Skoru: %" + (int)(sla.targetFaithfulness() * 100));
}
```

⚠️ Halüsinasyon, Güvenlik & Mülakat Tuzağı

🇹🇷 MÜLAKAT TUZAĞI VE HALÜSİNASYON

En Yaygın Hata: Mülakatçıyla konuşmadan sessizce tahtaya çizim yapmaktır. Mülakat bir monolog veya sınav değil; gelecekteki iş arkadaşınızla yaptığınız mimari bir beyin fırtınasıdır (Collaborative Dialogue). Her kararınızı ('Burada pgvector seçiyorum çünkü…') sesli olarak gerekçelendirin.

⚠️ Hallucination & Interview Trap

🇬🇧 INTERVIEW TRAP & HALLUCINATION RISK

The Silent Monologue Failure: Working in absolute silence while frantically sketching boxes on the whiteboard. A system design round is an interactive engineering collaboration. Always narrate your trade-offs aloud: 'I am opting for PostgreSQL pgvector here over Pinecone because our query volume is sub-1M vectors and we require ACID joins with user ACL tables.'

🎯 Mülakatta Hatırlanacak Altın Çıkarımlar

- İlk 5 dakikayı mutlaka gereksinimleri netleştirmeye ve QPS/TTFT sayılarını belirlemeye ayırın.
- Mimariyi basitten başlatın; ardından ölçek, gecikme ve güvenlik katmanlarıyla derinleştirin.
- Mülakat boyunca her seçimin ardındaki 'Trade-off'u mutlaka sesli olarak ifade edin.

🎯 Key Takeaways for the Interview

- Devote the first 5 minutes strictly to scope clarification and non-functional SLA targets.
- Start with an intuitive baseline architecture, then evolve it under scale and security pressure.
- Articulate the precise trade-offs behind every vector store, model, and chunking decision.