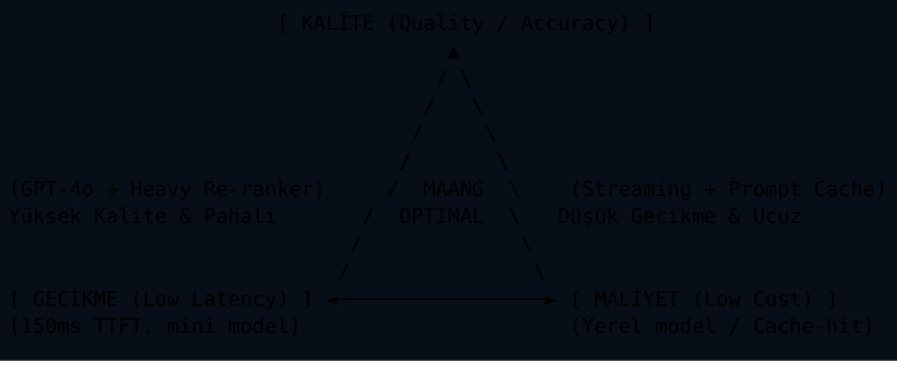
59

BÖLÜM: AI GÜVENLİĞİ, GÖZLEMLENEBILIRLIK & MAANG MÜLAKAT USTALIĞI | MODULE: AI SECURITY, OBSERVABILITY & THE MAANG INTERVIEW MASTERY RUBRIC

AI Mülakatlarında 'Trade-off' Savunusu: Latency vs Quality vs Cost

The Holy Trinity of AI Trade-offs: Latency vs Quality vs Cost Trilemma

🤖 AI Mimarisi & Veri Akış Şeması / 🤖 AI Architecture & Flow



💡 Aptala Anlatım (ELI5 Metaforu) / 💡 ELI5 Metaphor

🇹🇷 TÜRKÇE (ELI5)

Bir restoranda yemek yerken üç şey istersiniz: Yemek dünyanın en lezzetli yemeği olsun (Kalite), masanıza 1 dakikada gelsin (Düşük Gecikme) ve fiyatı sadece 10 TL olsun (Düşük Maliyet)! Gerçek hayatta bu üçünün aynı anda olması imkansızdır (Trilemma): Ya lezzetli ve hızlı olur ama pahalıdır; ya ucuz ve hızlıdır ama lezzetsizdir. Bir AI Engineer'ın ustalığı bu üçgenin ortasında durabilmektir: Basit soruları ucuz ve hızlı çözüp, sadece kritik kararlarda en kaliteli modeli devreye sokarak mükemmel dengeyi kurmaktır!

🇬🇧 ENGLISH (ELI5)

The classic engineering trilemma applied to AI: You demand Michelin-star quality, instantaneous 100ms delivery, and a price tag of $0.001. In reality, you can only pick two! Maximizing quality (GPT-4o + multi-agent debate + cross-encoder rerank) blows your latency and token budget. Minimizing cost and latency (quantized local model with zero context) destroys answer quality. A Staff+ AI Engineer masterfully balances this triangle through dynamic caching, speculative routing, and tiered fallbacks!

🔍 MAANG Seviyesi Teknik Derinlik / 🔍 MAANG-Level Technical Deep-Dive

🇹🇷 MAANG DERİNLEMESİNE ANALİZ

Trilemma Dengeleme Stratejileri: 1) Kalite Odaklı Senaryolar (Hukuk, Tıp, Finans): Gecikme ve maliyet ikinci plandadır. GPT-4o, HyDE, Cross-Encoder Reranking ve LLM-as-a-Judge zorunludur. 2) Gecikme Odaklı Senaryolar (Kod tamamlama, Sesli Asistan): Kaliteden ufak ödün verilebilir. GPT-4o-mini, Streaming (SSE), küçük chunk boyutları ve aggressively debounced çağrılar kullanılır. 3) Maliyet Odaklı Senaryolar (Kitle müşteri desteği): Semantik önbellekleme (Cache hit oranı %60+), Prompt Caching ve Model Routing ile maliyet %80 baskılanır.

🇬🇧 MAANG TECHNICAL DEEP-DIVE

Engineering the Trilemma Trade-Off Surface: 1) High-Stakes Domains (Medical, Financial, Legal): Quality is non-negotiable. Accept +1,000ms latency and $0.05/call using GPT-4o, multi-step ReAct, and dual cross-encoders. 2) Real-Time Interactive Surfaces (Voice, Code Autocomplete): Latency is king (SLA <200ms). Sacrifice marginal accuracy by deploying GPT-4o-mini with speculative streaming. 3) Massive Consumer Scale (Free Tier Support): Unit economics dominate. Drive cache-hit ratios past 60% via Redis semantic caches and aggressive prompt prefix deduplication.

⚡ Java 25, Spring AI & LangChain4j Kodu

⚡ Java 25 & OpenAI Implementation

```
// Java 25: AI Trilemma Strateji Seçici Modeli
public class AiTrilemmaGovernor {
    public enum PriorityProfile { QUALITY_FIRST, LATENCY_FIRST, COST_FIRST, BALANCED_PRODUCTION }

    public record ExecutionStrategy(String model, boolean useReranker, boolean enableStreaming,
boolean checkCache) {}

    public static ExecutionStrategy determineStrategy(PriorityProfile profile) {
        return switch (profile) {
            case QUALITY_FIRST -> new ExecutionStrategy("gpt-4o", true, false, false);
            case LATENCY_FIRST -> new ExecutionStrategy("gpt-4o-mini", false, true, true);
            case COST_FIRST    -> new ExecutionStrategy("gpt-4o-mini", false, false, true);
            case BALANCED_PRODUCTION -> new ExecutionStrategy("gpt-4o-mini", true, true, true);
        };
    }
}

void main() {
    var strategy =
AiTrilemmaGovernor.determineStrategy(AiTrilemmaGovernor.PriorityProfile.BALANCED_PRODUCTION);
    IO.println("MAANG Dengeli Üretim Stratejisi:");
    IO.println("Model: " + strategy.model() + " | Re-ranker: " + strategy.useReranker() + " |
Streaming: " + strategy.enableStreaming());
}
```

⚠️ Halüsinasyon, Güvenlik & Mülakat Tuzağı

⚠️ Hallucination & Interview Trap

🇹🇷 MÜLAKAT TUZAĞI VE HALÜSİNASYON

Mülakatın Altın Kuralı: 'Biz sistemimizde her yerde en büyük modeli kullandık, hiçbir maliyet hesabı yapmadık' demek bir mühendis için intihardır. Mülakatçıya daima 'Bu kararım şu kadar maliyet tasarrufu sağladı ancak gecikmeyi 50ms artırdı; bu bizim SLA sınırlarımız içindedir' şeklinde takas (Trade-off) analizi sunun.

🇬🇧 INTERVIEW TRAP & HALLUCINATION RISK

Cardinal interview sin: Stating that 'we always use the biggest model with unlimited context because it gives the best answer'. Senior engineers justify every millisecond and every micro-cent: 'We accept a 40ms reranking latency overhead because it elevates our precision@3 by 22%, saving downstream support escalations.'

🎯 Mülakatta Hatırlanacak Altın Çıkarımlar

🎯 Key Takeaways for the Interview

- AI Sistem Tasarımı; Kalite, Gecikme ve Maliyet arasındaki üçlü dengeyi (Trilemma) yönetme sanatıdır.
- Hiçbir mimari karar 'mükemmel' değildir; her kararın bir bedeli ve ödünleşimi (Trade-off) vardır.
- Mülakatçıları etkileyen şey en yeni teknolojiler değil, bu ödünleşimleri sayısal savunabilmenizdir.

- AI engineering is the discipline of navigating the Quality, Latency, and Cost trilemma.
- No architecture is unilaterally perfect; every design choice carries explicit trade-offs.
- Interviewers are swayed by your ability to quantify and defend these architectural trade-offs.